

# INSTITUTO POLITÉCNICO NACIONAL

---

UNIDAD PROFESIONAL INTERDISCIPLINARIA DE  
INGENIERÍA Y CIENCIAS SOCIALES Y  
ADMINISTRATIVAS



*LICENCIATURA EN CIENCIAS DE LA INFORMÁTICA*

*MINERÍA DE DATOS (7CM77)*

*PROF. ANDRADE CEDILLO MARCO FERNANADO*

## PROYECTO KDD



NOMBRE DEL ALUMNO:

ALVARADO SAN JUAN ANTONIO

# Índice

---

|                                           |    |
|-------------------------------------------|----|
| Introducción.....                         | 4  |
| Marco conceptual de KDD.....              | 4  |
| Planteamiento del problema.....           | 5  |
| Objetivo general .....                    | 5  |
| Objetivos específicos .....               | 5  |
| Objetivo analítico.....                   | 6  |
| Métricas de éxito.....                    | 6  |
| Restricciones del caso .....              | 6  |
| Comprensión del negocio .....             | 7  |
| Resumen ejecutivo del proyecto .....      | 7  |
| FASE 2: COMPRENSIÓN DE LOS DATOS .....    | 8  |
| Introducción .....                        | 8  |
| Inventario de fuentes de datos .....      | 8  |
| Descripción del dataset.....              | 9  |
| Diccionario de datos .....                | 9  |
| Análisis exploratorio inicial .....       | 11 |
| Calidad inicial de los datos.....         | 11 |
| 6.1 Valores nulos.....                    | 11 |
| 6.3 Integridad de datos .....             | 12 |
| 6.4 Limitaciones del dataset .....        | 12 |
| Evaluación de idoneidad de los datos..... | 12 |
| Conclusión de la fase .....               | 12 |
| Fase 3: Preparación de los datos .....    | 13 |
| Introducción .....                        | 13 |
| Objetivo de la fase .....                 | 13 |
| Diseño del pipeline ETL.....              | 14 |
| Extracción de datos .....                 | 14 |
| Limpieza de datos.....                    | 15 |

|                                                               |    |
|---------------------------------------------------------------|----|
| Detección de outliers .....                                   | 15 |
| Transformación y enriquecimiento.....                         | 15 |
| Construcción del esquema estrella.....                        | 16 |
| Validación de calidad .....                                   | 16 |
| Dataset final listo para EDA .....                            | 17 |
| Conclusión de la fase .....                                   | 17 |
| Autoevaluación reflexiva (incluir en documento):.....         | 18 |
| Proyecto integrador: .....                                    | 19 |
| Fase 1: Diagnóstico y Diseño del Proceso .....                | 19 |
| Introducción: .....                                           | 19 |
| Metodología de Investigación .....                            | 19 |
| Diseño de la investigación etnográfica simulada.....          | 19 |
| Criterios de selección de perfiles.....                       | 19 |
| Limitaciones reconocidas .....                                | 20 |
| Investigación Etnográfica: Registros de Entrevista .....      | 20 |
| Tienda de tecnología — TechZone Satélite .....                | 20 |
| Ferretería especializada — Ferretería El Clavo Dorado .....   | 23 |
| Librería independiente — Librería Letra Viva .....            | 25 |
| Perfiles de Madurez Analítica .....                           | 28 |
| Descripción detallada por perfil .....                        | 29 |
| Perfil A — Madurez Caótica (Ferretería El Clavo Dorado) ..... | 29 |
| Perfil B — Madurez Emergente (TechZone Satélite) .....        | 29 |
| Perfil C — Madurez Estructurada (Librería Letra Viva).....    | 30 |
| Decisiones Críticas Recurrentes por Segmento .....            | 30 |
| Tienda de Tecnología (Perfil Emergente).....                  | 30 |
| Ferretería Especializada (Perfil Caótico).....                | 31 |
| Librería Independiente (Perfil Estructurado).....             | 32 |
| Especificación de Necesidades KDD por Impacto .....           | 32 |
| Fase 2: Diseño de la Arquitectura.....                        | 34 |
| Introducción .....                                            | 34 |
| Enfoque de Arquitectura en Tres Capas .....                   | 35 |

|                                                          |    |
|----------------------------------------------------------|----|
| Capa 1: Comprensión y Preparación (Base del KDD) .....   | 35 |
| Capa 2: Análisis Exploratorio (EDA) .....                | 36 |
| Capa 3: Sistema de Recomendaciones Accionables .....     | 37 |
| Diagrama de Flujo del Proceso KDD Adaptado a PYMES ..... | 39 |
| Ontología de Métricas por Industria.....                 | 39 |
| Conclusión de la Fase.....                               | 40 |
| FASE 3: IMPLEMENTACIÓN DEL PROTOTIPO FUNCIONAL.....      | 40 |
| Introduccion .....                                       | 40 |
| Objetivo de la fase .....                                | 41 |
| 1. Asistente de Comprensión del Negocio.....             | 41 |
| 2. Pipeline ETL .....                                    | 42 |
| 3. Dashboard de EDA.....                                 | 43 |
| 4. Generador de Recomendaciones.....                     | 44 |
| Tecnologías utilizadas.....                              | 45 |
| Flujo funcional del prototipo .....                      | 45 |
| Validación del prototipo .....                           | 46 |
| Conclusión de la fase .....                              | 46 |
| Fase 5: Estrategia de Adopción y Sostenibilidad .....    | 47 |

## Introducción

---

La Minería de Datos es una disciplina orientada a extraer conocimiento útil a partir de grandes volúmenes de información. No obstante, su valor no depende únicamente de aplicar algoritmos, sino de seguir un proceso metodológico que conecte los datos con decisiones reales de negocio. En este contexto, el proceso KDD (Knowledge Discovery in Databases) constituye un marco sistemático que organiza el trabajo en fases interdependientes: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado y evaluación. El proyecto RetailMax se centra en las fases iniciales, ya que son las que permiten traducir una necesidad empresarial en un problema analítico claro, evaluar la idoneidad de los datos y preparar una base sólida para análisis posteriores. Este enfoque evita errores comunes como aplicar algoritmos sin entender el problema o trabajar con datos que aún no son confiables para la toma de decisiones.

## Marco conceptual de KDD

---

El proceso KDD puede entenderse como una secuencia estructurada para descubrir conocimiento útil en bases de datos.

Sus cinco fases son: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado y evaluación. La lógica del KDD radica en que cada etapa depende de la anterior: no es posible modelar correctamente si el problema de negocio está mal definido, ni si los datos no fueron previamente limpiados e integrados.

Por ello, en este proyecto se priorizan las fases iniciales, ya que son las que convierten una necesidad vaga de la empresa en un objetivo analítico medible y accionable. El propio material enfatiza que la minería de datos no debe verse como un conjunto aislado de algoritmos, sino como un proceso sistemático para encontrar patrones útiles y no solo técnicamente interesantes.

## Planteamiento del problema

---

RetailMax es una cadena minorista con 50 tiendas que enfrenta un problema de desempeño comercial: aunque el volumen de transacciones ha aumentado, el valor promedio por compra ha disminuido un 8% durante el último año.

Esta situación indica que el crecimiento en operaciones no se ha traducido en un incremento proporcional del ingreso por ticket, lo que afecta la rentabilidad del negocio. Ante este escenario, el equipo de TI propuso aplicar de inmediato algoritmos de asociación de mercado; sin embargo, la dirección de operaciones exige primero un análisis riguroso basado en el proceso KDD.

En consecuencia, el problema no consiste solamente en “aplicar minería de datos”, sino en comprender por qué el ticket promedio se ha estancado y cómo identificar oportunidades de venta cruzada y combinación de productos que permitan elevar el monto de compra sin recurrir a cambios de precio ni a campañas publicitarias masivas.

## Objetivo general

---

Desarrollar la fase de comprensión del negocio del proyecto KDD para RetailMax, traduciendo el problema del estancamiento del ticket promedio en un objetivo analítico claro, medible y alineado con las restricciones operativas del caso, a fin de establecer una base sólida para las siguientes fases del proyecto de minería de datos.

## Objetivos específicos

1. Identificar el problema central de negocio que afecta a RetailMax.
2. Traducir dicho problema en un objetivo analítico medible y orientado a resultados.
3. Definir métricas cuantificables que permitan evaluar el éxito del proyecto.
4. Documentar las restricciones operativas y económicas que limitan la estrategia de solución.

5. Fundamentar la importancia de la fase de comprensión del negocio dentro del proceso KDD.
6. Dejar establecida la lógica de negocio que guiará la comprensión de datos y la preparación posterior.

### **Objetivo analítico**

Identificar combinaciones de productos y segmentos de cliente que aumenten el valor promedio del ticket en un 12% en un periodo de 6 meses, sin realizar cambios en precios ni implementar campañas publicitarias masivas. Esta formulación responde directamente a lo solicitado por el instructivo y convierte el problema de negocio en una meta analítica medible, específica y alineada con las restricciones reales del caso.

### **Métricas de éxito**

---

Las métricas de éxito definidas para el proyecto son las siguientes:

- Incrementar en **12%** el valor promedio del ticket.
- Reducir en **15%** las transacciones de bajo valor, definidas como aquellas menores a \$100.
- Mejorar en **20%** las ventas cruzadas en categorías complementarias.

Estas métricas son adecuadas porque convierten el objetivo de negocio en indicadores cuantificables y comparables, permitiendo evaluar si el proyecto genera impacto comercial real y no solo hallazgos técnicos.

### **Restricciones del caso**

El proyecto debe respetar las siguientes restricciones:

- No se permite inversión en nuevas herramientas por encima de **\$500**.
- No se permite modificar los precios de los productos.
- No se permite implementar campañas masivas de marketing.

Estas restricciones son relevantes porque obligan a enfocar la solución en el aprovechamiento inteligente de los datos ya disponibles, la identificación de patrones de compra y la mejora de estrategias comerciales sin depender de cambios externos costosos o agresivos.

## **Comprensión del negocio**

---

La comprensión del negocio constituye la fase inicial y estratégica del proceso KDD, ya que permite traducir una necesidad organizacional en un objetivo analítico concreto. En el caso de RetailMax, esta fase parte de la identificación de una disminución del ticket promedio, a pesar del aumento en el volumen de transacciones. A partir de ello, se definen las metas cuantificables del proyecto, así como las restricciones que condicionan la solución. Su importancia radica en que orienta el resto del proceso analítico, evitando que las etapas posteriores se desarrollen sin dirección estratégica o sin pertinencia para la empresa.

## **Resumen ejecutivo del proyecto**

---

RetailMax enfrenta una disminución del 8% en el valor promedio del ticket, a pesar de que el volumen de transacciones ha crecido en el último año. Para atender este problema, el proyecto plantea un enfoque basado en KDD, comenzando por la comprensión del negocio. El objetivo analítico consiste en identificar combinaciones de productos y segmentos de cliente que permitan aumentar el ticket promedio en 12% en 6 meses, sin cambiar precios ni lanzar campañas publicitarias masivas. El éxito del proyecto se medirá mediante tres indicadores: incremento del ticket promedio, reducción de tickets bajos y mejora de ventas cruzadas. Esta fase deja establecido el marco estratégico que guiará la comprensión y preparación de los datos en las etapas siguientes.



## FASE 2: COMPRENSIÓN DE LOS DATOS

### Proyecto KDD: RetailMax 2026

#### Introducción

---

La fase de comprensión de los datos constituye un paso fundamental dentro del proceso KDD (Knowledge Discovery in Databases), ya que permite analizar la naturaleza, estructura y calidad de la información disponible antes de proceder a su preparación y posterior modelado.

En esta etapa, se busca identificar las características principales del conjunto de datos, evaluar su idoneidad respecto al objetivo analítico del proyecto y detectar posibles problemas de calidad que puedan afectar los resultados. Para el caso de RetailMax, se ha trabajado con un dataset sintético diseñado específicamente para simular el comportamiento de ventas en el sector minorista de tecnología y accesorios durante un periodo de 12 meses.

#### Inventario de fuentes de datos

---

Dado que el proyecto se basa en un entorno simulado, se definieron tres fuentes de datos que representan los sistemas típicos de una organización minorista:

| Fuente                                 | Tipo | Volumen estimado | Descripción                                                               | Uso en el proyecto                                                       |
|----------------------------------------|------|------------------|---------------------------------------------------------------------------|--------------------------------------------------------------------------|
| ERP (Enterprise Resource Planning)     | CSV  | 50,000 registros | Contiene transacciones de ventas (productos, precios, cantidades, fechas) | Fuente principal para análisis de tickets y comportamiento transaccional |
| CRM (Customer Relationship Management) | CSV  | 30,000 registros | Información de clientes y segmentación (Individual, PyME, Empresa)        | Segmentación complementaria y atributos de cliente                       |

|                              |      |                  |                                              |                                                   |
|------------------------------|------|------------------|----------------------------------------------|---------------------------------------------------|
| Web (Logs de comportamiento) | Logs | 200,000 sesiones | Datos de navegación y comportamiento digital | Contexto de interacción digital y canal de origen |
|------------------------------|------|------------------|----------------------------------------------|---------------------------------------------------|

Se determinó que la fuente más relevante para el objetivo del proyecto es el ERP, ya que contiene la información transaccional necesaria para analizar patrones de compra y combinaciones de productos.

### Descripción del dataset

El dataset denominado `datos_retailmax_2026.csv` contiene un total de 50,000 transacciones simuladas correspondientes al año 2026. Cada registro representa una compra individual realizada en una de las 50 tiendas de la cadena RetailMax, con cobertura temporal del 2026-01-01 al 2026-12-31.

El diseño del dataset incorpora características clave del problema:

- Cobertura de 12 meses (enero a diciembre)
- Patrón estacional con picos en los meses 3, 6 y 9
- Enfoque en productos del sector tecnología y accesorios
- Inclusión de segmentación de clientes
- Presencia controlada de valores nulos (7.3%)

### Diccionario de datos

A continuación, se presenta la descripción de las variables incluidas en el dataset:

| Variable | Tipo de dato | Descripción | Valores posibles |
|----------|--------------|-------------|------------------|
|----------|--------------|-------------|------------------|

|                         |         |                                             |                                          |
|-------------------------|---------|---------------------------------------------|------------------------------------------|
| <b>id_transaccion</b>   | Entero  | Identificador único de la transacción       | Secuencial                               |
| <b>fecha</b>            | Fecha   | Fecha en la que se realizó la compra        | 2026-01-01 a 2026-12-31                  |
| <b>mes</b>              | Entero  | Mes de la transacción                       | 1–12                                     |
| <b>id_cliente</b>       | Entero  | Identificador del cliente                   | Catálogo interno del caso                |
| <b>segmento_cliente</b> | Texto   | Tipo de cliente observado en la transacción | Individual, PyME, Empresa, NULL          |
| <b>producto</b>         | Texto   | Producto adquirido                          | 20 productos del catálogo RetailMax      |
| <b>categoria</b>        | Texto   | Categoría del producto                      | Cómputo, Accesorios                      |
| <b>precio_unitario</b>  | Decimal | Precio por unidad del producto              | > 0                                      |
| <b>cantidad</b>         | Entero  | Número de unidades compradas                | 1–4                                      |
| <b>metodo_pago</b>      | Texto   | Forma de pago                               | Tarjeta, Efectivo, Transferencia, PayPal |
| <b>Tienda</b>           | Texto   | Ubicación de la tienda                      | Catálogo de 50 tiendas                   |
| <b>canal_venta</b>      | Texto   | Canal por el que se generó la transacción   | TIENDA, WEB, TELEFONO                    |
| <b>Estado</b>           | Texto   | Estado de la transacción                    | COMPLETADA, CANCELADA                    |

|                     |         |                          |                   |
|---------------------|---------|--------------------------|-------------------|
| <b>total_ticket</b> | Decimal | Monto total de la compra | precio * cantidad |
|---------------------|---------|--------------------------|-------------------|

## Análisis exploratorio inicial

---

- El análisis preliminar del dataset confirmó que la mayor concentración de transacciones se ubica en los meses 3, 6 y 9, siendo junio el mes con mayor volumen (6,030 transacciones). Esta distribución respalda el patrón estacional definido para el caso RetailMax. Se observa una distribución de transacciones a lo largo de los 12 meses, con incrementos significativos en marzo, junio y septiembre, lo que refleja ciclos de lanzamiento de productos tecnológicos.
- Los productos más frecuentes corresponden a dispositivos tecnológicos y accesorios, alineados con el sector definido.
- El monto total de compra (total\_ticket) presenta variabilidad dependiendo del tipo de producto y la cantidad adquirida.
- La segmentación de clientes permite distinguir entre diferentes tipos de compradores, aunque presenta limitaciones por la presencia de valores nulos.

## Calidad inicial de los datos

---

Durante la evaluación de calidad del dataset, se identificaron los siguientes aspectos relevantes:

### 6.1 Valores nulos

Se detectó que la variable segmento\_cliente contiene 3,646 valores nulos, equivalentes a 7.29% del total. Este comportamiento fue diseñado deliberadamente para cumplir la configuración del caso y representa una limitación para análisis segmentados directos si no se realiza tratamiento posterior.

### 6.3 Integridad de datos

No se detectaron valores negativos en variables críticas como precio\_unitario, cantidad o total\_ticket. Además, el dataset corregido presenta 50 tiendas activas y 20 productos con ventas, por lo que la estructura base es consistente con el caso de negocio.

### 6.4 Limitaciones del dataset

- No se cuenta con información demográfica detallada de los clientes.
- El dataset es sintético, por lo que, aunque es realista, no refleja completamente la complejidad de datos reales.
- La variable segmento\_cliente presenta valores faltantes que deberán tratarse en fases posteriores.

## Evaluación de idoneidad de los datos

---

Con base en el análisis realizado, se concluye que el dataset es adecuado para el objetivo del proyecto, ya que:

- Permite analizar transacciones a nivel producto
- Incluye variables suficientes para identificar patrones de compra
- Contiene información temporal para detectar estacionalidad
- Integra segmentación básica de clientes

Sin embargo, debido a las limitaciones en datos demográficos, se toma la decisión de enfocar el análisis a nivel de **transacción y producto**, en lugar de realizar un análisis profundo a nivel individual de cliente.

## Conclusión de la fase

---

La fase de comprensión de los datos permitió validar la disponibilidad, estructura y calidad de la información necesaria para el proyecto RetailMax. Se identificaron tanto fortalezas del

dataset, como su alineación con el objetivo analítico, como áreas de mejora relacionadas con la calidad de ciertos atributos.

Este análisis establece una base sólida para la siguiente etapa del proceso KDD, correspondiente a la preparación de los datos, donde se abordarán los problemas detectados y se optimizará el dataset para su posterior análisis y modelado.

## **Fase 3: Preparación de los datos**

### **Introducción**

---

La fase de preparación de los datos constituye la tercera etapa del proceso KDD y representa el punto en el que la información identificada y evaluada en la fase anterior se transforma en un conjunto de datos estructurado, consistente y apto para análisis posteriores. En esta etapa no solo se corrigen problemas de calidad, sino que también se realizan integraciones, enriquecimientos y transformaciones que permiten convertir los datos en una base analítica con valor real para la toma de decisiones.

En el caso de RetailMax, esta fase se orientó a construir un pipeline ETL funcional capaz de tomar el dataset sintético generado para el año 2026, aplicar procesos de limpieza y normalización, derivar atributos útiles para el negocio y estructurar la información en un modelo dimensional tipo esquema estrella. De esta manera, la preparación de los datos deja listo el entorno para la siguiente fase del proyecto, correspondiente al análisis exploratorio avanzado.

### **Objetivo de la fase**

---

El objetivo de esta fase consiste en transformar el dataset inicial de RetailMax en un conjunto de datos limpio, consistente y estructurado, integrando la información relevante de las fuentes simuladas ERP, CRM y Web, corrigiendo problemas de calidad, generando variables

derivadas orientadas al análisis y construyendo un esquema estrella para OLAP que permita soportar la siguiente etapa del proyecto KDD.

## Diseño del pipeline ETL

---

Para cumplir con los requerimientos del proyecto, se implementó el archivo *pipeline\_kdd\_2026.py*, cuyo propósito es ejecutar de forma ordenada las tres primeras fases del KDD: comprensión del negocio, comprensión de los datos y preparación de los datos.

El pipeline parte del archivo *datos\_retailmax\_2026.csv*, generado previamente con 50,000 transacciones sintéticas del sector minorista de tecnología y accesorios, y produce como salidas principales un conjunto de tablas en esquema estrella y un archivo JSON con métricas de calidad.

El dataset fue construido bajo una configuración específica del caso RetailMax: 12 meses de transacciones simuladas, patrón estacional con picos en los meses 3, 6 y 9, restricción de segmentación a *PYME*, *EMPRESA* e *INDIVIDUAL*, y 7.3% de valores nulos en *segmento\_cliente*. Además, incluye variables comerciales y de comportamiento digital como *id\_transaccion*, *fecha*, *producto*, *tienda*, *estado*, *total\_ticket*, *canal\_venta*.

## Extracción de datos

---

En la etapa de extracción, el pipeline carga el dataset base desde el directorio de trabajo y lo interpreta como la integración lógica de tres fuentes de información: ERP, CRM y Web. La fuente ERP aporta las transacciones históricas de ventas; la fuente CRM proporciona la segmentación básica de cliente y el canal comercial; y la fuente Web agrega información relacionada con el comportamiento digital, como tipo de dispositivo, canal de origen, páginas vistas y tiempo de permanencia.

Esta estructura cumple con lo solicitado por el PDF, que exige integrar tres fuentes con normalización de esquemas dentro de la fase de preparación.

## Limpieza de datos

---

Una vez cargada la información, se realizaron procesos de limpieza orientados a asegurar la calidad mínima del conjunto de datos. Se eliminaron 888 transacciones con estado **CANCELADA**, no se detectaron montos inválidos ni duplicados eliminables y se imputaron 3,578 valores faltantes de `segmento_cliente` con la categoría DESCONOCIDO.

Asimismo, se normalizaron los campos categóricos para asegurar consistencia semántica, especialmente en categorías de producto y variantes de segmentación. Con ello, al finalizar el proceso no quedaron valores nulos en campos críticos para el análisis dimensional.

## Detección de outliers

---

Como parte del aseguramiento de calidad, se implementó una detección de outliers contextuales sobre la variable ***total\_ticket*** mediante un criterio basado en el rango intercuartílico. En lugar de eliminar dichos registros, el pipeline los marcó con la variable ***outlier\_contextual*** para conservar la trazabilidad de valores atípicos. En la ejecución validada se identificaron 8,418 outliers, utilizando un umbral superior de 4498.53.

Esta decisión es adecuada porque permite conservar información potencialmente valiosa para el análisis posterior sin alterar artificialmente la distribución del dataset limpio.

## Transformación y enriquecimiento

---

Además de la limpieza, la fase incorporó una serie de transformaciones orientadas a enriquecer el análisis. Se generaron variables temporales como ***mes***, ***anio***, ***trimestre*** y ***dia\_semana***, con el fin de facilitar el estudio de la estacionalidad y del comportamiento transaccional a lo largo del tiempo.

También se derivaron variables de negocio como ***ticket\_alto***, ***ticket\_bajo***, ***canal\_digital*** y ***es\_pico\_temporada***, que permiten clasificar las transacciones



según su relevancia económica, su medio de interacción y su correspondencia con los meses de mayor actividad definidos en la lógica del caso.

De igual forma, se mantuvo y aprovechó la variable ***complementariedad\_estimada***, vinculando directamente la fase de preparación con el objetivo analítico centrado en detectar oportunidades de ventas cruzadas.

## Construcción del esquema estrella

---

Como parte de la etapa de carga, el pipeline estructuró los datos en un modelo dimensional tipo esquema estrella. Este modelo quedó conformado por una tabla de hechos denominada **fact\_ventas** y cinco dimensiones: **dim\_tiempo**, **dim\_producto**, **dim\_cliente**, **dim\_canal** y **dim\_tienda**. La tabla de hechos concentra las métricas principales de cada transacción, mientras que las dimensiones permiten analizar la información desde perspectivas temporales, de producto, de cliente, de canal y de tienda.

| Hechos | Tiempo | Producto | Cliente | Canal | Tienda |
|--------|--------|----------|---------|-------|--------|
| 49112  | 365    | 20       | 12      | 50    | 50     |

## Validación de calidad

---

La validación final del pipeline se documentó en el archivo ***metricas\_calidad\_kdd\_2026.json***. De acuerdo con este reporte, el proceso recibió 50,000 registros de entrada y generó 49,112 registros de salida, lo que equivale a una tasa de retención de 98.22%.

Asimismo, se documentó la eliminación de 888 transacciones canceladas, cero duplicados eliminados, cero valores nulos en campos críticos al finalizar el proceso y un ticket promedio limpio de 2503.22 y un mes pico real correspondiente a junio (mes 6). El segmento con mayor ticket promedio en la ejecución validada fue DESCONOCIDO, lo cual debe interpretarse

como evidencia de que los registros imputados aún conservan peso analítico y que la calidad de la segmentación sigue siendo un punto de atención.

| Retención | Outliers marcados | Nulos en llaves foráneas | Consistencia dimensional |
|-----------|-------------------|--------------------------|--------------------------|
| 98.22%    | 8418 (17.14%)     | 0                        | Verificada               |

## Dataset final listo para EDA

---

Como resultado de la fase de preparación, RetailMax cuenta con un dataset limpio, enriquecido y estructurado, listo para emplearse en el análisis exploratorio avanzado. Este resultado representa una base sólida para las siguientes etapas del proyecto, ya que permite trabajar con información consistente, documentada y alineada con el objetivo analítico del negocio.

Además, el archivo JSON generado actúa como evidencia formal del estado de calidad alcanzado, mientras que las tablas del esquema estrella sirven como soporte técnico para consultas analíticas y futuras tareas de modelado.

## Conclusión de la fase

---

La fase de preparación de los datos permitió convertir el dataset sintético inicial en una estructura analítica robusta y funcional para el proyecto RetailMax.

A través del pipeline ETL se integraron fuentes simuladas, se limpiaron y transformaron los datos, se detectaron valores atípicos, se derivaron variables relevantes para el negocio y se construyó un esquema estrella con integridad dimensional verificada.

En consecuencia, esta etapa no solo cumple con los requerimientos del proyecto establecidos en el PDF, sino que también deja una plataforma confiable para continuar con el análisis exploratorio y el modelado posterior dentro del proceso KDD.

## Autoevaluación reflexiva (incluir en documento):

---

1. ¿Qué suposición inicial sobre los datos se desmintió al analizar el dataset sintético?
2. Si tuvieras solo 24 horas para entregar resultados preliminares, ¿qué fase del KDD priorizarías y por qué?
3. ¿Cómo explicarías a un gerente no técnico por qué invertir tiempo en preparación de datos en lugar de aplicar algoritmos inmediatamente?
4. ¿Qué métrica usarías para demostrar el ROI de las fases iniciales del KDD a la gerencia escéptica?
5. Si el director de operaciones argumenta "necesitamos resultados ya, no análisis", ¿qué argumento usarías para defender el proceso KDD estructurado?

## **Proyecto integrador:**

### **Fase 1: Diagnóstico y Diseño del Proceso**

#### **Introducción:**

La Fase 1 del Proyecto Integrador "Plataforma KDD para PYMES Minoristas" aplica directamente la Fase 1 del proceso KDD (Comprensión del Negocio) al contexto específico de las pequeñas y medianas empresas minoristas en México. El objetivo de esta fase es producir un diagnóstico estructurado, basado en investigación etnográfica simulada, que permita identificar con precisión las necesidades analíticas reales de tres tipos representativos de negocio: tiendas de tecnología, ferreterías especializadas y librerías independientes.

De acuerdo con el instructivo del profesor, esta investigación busca responder tres preguntas centrales mediante entrevistas guiadas por escenarios con dueños y gerentes simulados:

- Cuáles han sido sus decisiones de inventario fallidas y qué datos habrían necesitado.
- Qué información sobre sus clientes cambiaría sus decisiones de venta.
- Qué datos necesitarían para aprobar una promoción con confianza.

#### **Metodología de Investigación**

##### **Diseño de la investigación etnográfica simulada**

La investigación se realizó mediante entrevistas estructuradas con tres perfiles de dueños o gerentes de PYMES minoristas representativos de la región centro de México. Para cada perfil se seleccionó un escenario verosímil que refleja las condiciones reales de operación: limitaciones de tiempo, recursos escasos y baja madurez analítica. Las entrevistas se condujeron con un guion de tres preguntas abiertas estandarizadas, idénticas para los tres perfiles, con el objetivo de permitir comparaciones directas entre segmentos.

##### **Criterios de selección de perfiles**

Los tres tipos de minorista seleccionados responden a criterios de representatividad sectorial y diversidad de madurez analítica. La tienda de tecnología fue elegida por su alineación directa con el caso RetailMax ya desarrollado en el Módulo 1, lo que permite construir continuidad metodológica. La ferretería fue elegida por representar el extremo de menor madurez analítica, donde la toma de decisiones es casi completamente intuitiva. La librería

independiente fue elegida por representar un caso intermedio-avanzado donde el dueño ya conceptualiza el valor del dato pero carece de herramientas para procesarlo.

### **Limitaciones reconocidas**

Al tratarse de investigación etnográfica simulada, las respuestas de los entrevistados son construcciones analíticas del equipo basadas en el conocimiento del contexto PYME mexicano, no en entrevistas reales. Esta limitación se documenta explícitamente y se considera aceptable dentro del marco académico del proyecto integrador. En una implementación real de la plataforma, esta fase requeriría entre 3 y 5 sesiones de campo por segmento con instrumentos de consentimiento informado.

### **Investigación Etnográfica: Registros de Entrevista**

#### **Tienda de tecnología — TechZone Satélite**

|                              |                                                      |
|------------------------------|------------------------------------------------------|
| Tipo de negocio:             | Tienda de tecnología                                 |
| Nombre del negocio:          | TechZone Satélite                                    |
| Ubicación:                   | Naucalpan, Estado de México                          |
| Entrevistado:                | Roberto Meneses (propietario, 12 años en el negocio) |
| Período:                     | Semana 1 — Investigación de campo simulada           |
| Perfil de madurez analítica: | Emergente                                            |

## Pregunta 1

### Pregunta del investigador:

Cuéntame la última vez que tomaste una decisión de inventario que resultó mal. ¿Qué datos tenías? ¿Qué te habría ayudado?

### Respuesta del entrevistado:

Pedí 40 unidades de una laptop gamer porque el representante me dijo que 'se estaba vendiendo muy bien en el norte'. Solo teníamos papel con las ventas del mes anterior. A fin de mes me quedaron 22. Lo que me habría ayudado es saber cuántas laptops de ese rango de precio vendí yo en los últimos tres meses, no lo que venden otras tiendas.

### Análisis KDD del equipo:

Decisión basada en información externa no verificable. Ausencia de historial de ventas propio por categoría y rango de precio. Necesidad de análisis de rotación por SKU.

## Pregunta 2

### Pregunta del investigador:

Si pudieras saber una cosa sobre tus clientes para mejorar ventas, ¿qué sería?

### Respuesta del entrevistado:

Saber quién regresa. Tengo clientes que llevan 5 años viniendo pero ni los conozco. Si supiera quién compra seguido, les podría avisar cuando llega algo nuevo que les podría interesar. Mis ventas grandes siempre son a los mismos, pero no sé cuáles son.

#### **Análisis KDD del equipo:**

Ausencia de segmentación de clientes recurrentes. Oportunidad de análisis de frecuencia de compra y valor de cliente. El dueño intuye la existencia de un segmento de alto valor pero no tiene datos para confirmarlo.

### **Pregunta 3**

#### **Pregunta del investigador:**

¿Qué información necesitarías para sentirte tranquilo al aprobar una promoción?

#### **Respuesta del entrevistado:**

Saber cuánto me cuesta de verdad la promoción. Cuando descuento un 15% en audífonos, no sé si gano más por volumen o si solo pierdo margen. Nunca lo he calculado con datos reales, lo hago a ojo.

#### **Análisis KDD del equipo:**

Ausencia de análisis de elasticidad precio-volumen. Sin herramientas de medición de impacto de promociones. El dueño reconoce la limitación y desea resolverla.

## Ferretería especializada — Ferretería El Clavo Dorado

|                              |                                                                |
|------------------------------|----------------------------------------------------------------|
| Tipo de negocio:             | Ferretería especializada                                       |
| Nombre del negocio:          | Ferretería El Clavo Dorado                                     |
| Ubicación:                   | Iztapalapa, CDMX                                               |
| Entrevistado:                | Esperanza Villanueva (gerente general, 20 años de experiencia) |
| Período:                     | Semana 1 — Investigación de campo simulada                     |
| Perfil de madurez analítica: | Caótica                                                        |

### Pregunta del investigador:

Cuéntame la última vez que tomaste una decisión de inventario que resultó mal. ¿Qué datos tenías? ¿Qué te habría ayudado?

### Respuesta del entrevistado:

Compramos 300 kilos de cemento más porque el proveedor nos dio descuento por volumen. Tres meses después seguíamos con la mitad porque ese mes no hubo obras en la zona. No teníamos nada, decidimos a ojo. Lo que nos habría ayudado es saber en qué meses se vende más el cemento aquí cerca.



**Análisis KDD del equipo:**

Decisión guiada por incentivo de proveedor sin análisis de demanda estacional propia. Datos completamente ausentes. Necesidad de análisis de estacionalidad por categoría de producto.

**Pregunta 2****Pregunta del investigador:**

Si pudieras saber una cosa sobre tus clientes para mejorar ventas, ¿qué sería?

**Respuesta del entrevistado:**

Quiero saber qué compran juntos. El que viene a comprar pintura siempre termina comprando brochas, pero no siempre se los ofrezco. Si supiera que siempre van juntos, los pondría juntos en la tienda o los ofrecería automáticamente.

**Análisis KDD del equipo:**

Intuición de reglas de asociación sin soporte de datos. Oportunidad directa de análisis de canasta de mercado (market basket analysis). Alta receptividad a recomendaciones de venta cruzada.

**Pregunta 3****Pregunta del investigador:**

¿Qué información necesitarías para sentirte tranquila al aprobar una promoción?

**Respuesta del entrevistado:**

Que alguien me diga qué productos se venden solos y cuáles necesitan impulso. Los que se venden solos no necesitan descuento. Los que no se mueven, tampoco sirve descontarlos porque la gente simplemente no los quiere.

**Análisis KDD del equipo:**

Comprensión intuitiva de la segmentación de productos por rotación. Reconocimiento de que el descuento no es solución universal. Necesita clasificación ABC de inventario basada en datos.

**Librería independiente — Librería Letra Viva**

|                              |                                                               |
|------------------------------|---------------------------------------------------------------|
| Tipo de negocio:             | Librería independiente                                        |
| Nombre del negocio:          | Librería Letra Viva                                           |
| Ubicación:                   | Coyoacán, CDMX                                                |
| Entrevistado:                | Rodrigo Espinoza (propietario-fundador, 8 años en el negocio) |
| Período:                     | Semana 1 — Investigación de campo simulada                    |
| Perfil de madurez analítica: | Estructurada                                                  |

**Pregunta 1**

**Pregunta del investigador:**

Cuéntame la última vez que tomaste una decisión de inventario que resultó mal. ¿Qué datos tenías? ¿Qué te habría ayudado?

**Respuesta del entrevistado:**

Pedí 20 ejemplares de un libro de filosofía porque el autor había dado una conferencia. Vendí 4 en dos meses. Tenía solo mi intuición y la reseña del proveedor. Lo que me habría ayudado es saber si mis clientes habituales compran ese tipo de libro. Porque resulta que el público de la conferencia no es mi público.

**Análisis KDD del equipo:**

El dueño ya articula el concepto de segmentación de clientes sin saberlo. Usa lenguaje más analítico que los otros casos. Existe un registro básico de ventas pero sin análisis. Necesita perfil de cliente por género literario.

**Pregunta 2****Pregunta del investigador:**

Si pudieras saber una cosa sobre tus clientes para mejorar ventas, ¿qué sería?

**Respuesta del entrevistado:**

Qué autor los hace volver. Tengo clientes que compran todo de ciertos autores. Si supiera eso, cuando llega una novedad de ese autor podría avisarles directamente.

Ahora lo hago de memoria con 5 o 6 clientes, pero tengo más de 300 clientes recurrentes.

#### **Análisis KDD del equipo:**

Necesidad de sistema de recomendación personalizada por historial de autor/género. El dueño ya practica manualmente con una muestra pequeña. Alta madurez conceptual: entiende el valor del dato pero carece de estructura para procesarlo.

### **Pregunta 3**

#### **Pregunta del investigador:**

¿Qué información necesitarías para sentirte tranquilo al aprobar una promoción?

#### **Respuesta del entrevistado:**

Saber si la promoción atrae nuevos clientes o solo descuenta a los que ya iban a comprar de todas formas. Ese es mi mayor miedo: hacer descuento y que solo los habituales aprovechen, que es plata que dejo de ganar sin beneficio real.

#### **Análisis KDD del equipo:**

Comprensión sofisticada del concepto de incrementalidad en promociones. El más avanzado de los tres perfiles. Requiere análisis de nuevos vs. recurrentes con y sin promoción. Candidato ideal para fase de validación del prototipo.

## Perfiles de Madurez Analítica

Con base en los registros de entrevista, el equipo clasificó cada tipo de minorista dentro de un continuo de madurez analítica de tres niveles: caótica, emergente y estructurada. Esta clasificación sigue el framework propuesto por Davenport y Harris (2007) adaptado al contexto PYME latinoamericano. Cada nivel describe la relación del negocio con sus propios datos y su capacidad para transformarlos en decisiones.

| Dimensión           | Caótica (Ferretería)                              | Emergente (Tecnología)                                    | Estructurada (Librería)                            |
|---------------------|---------------------------------------------------|-----------------------------------------------------------|----------------------------------------------------|
| Registro de datos   | Sin registro sistemático. Solo recibos y memoria. | Registro parcial en hoja de cálculo o sistema POS básico. | Registro en sistema POS con historial de clientes. |
| Uso de datos        | No se usan. Decisiones 100% intuitivas.           | Se consultan ocasionalmente, sin metodología.             | Se revisan semanalmente, sin análisis formal.      |
| Lenguaje del dueño  | Habla de 'sensaciones' y 'experiencia'.           | Habla de 'lo que se vendió' sin profundizar.              | Habla de 'segmentos' y 'clientes habituales'.      |
| Tolerancia al error | Alta: errores no se conectan con decisiones.      | Media: reconoce errores pero no los mide.                 | Baja: identifica errores y busca causa.            |
| Mayor necesidad KDD | Recolección básica de datos y estacionalidad.     | Segmentación de clientes y rotación de productos.         | Recomendación personalizada e incrementalidad.     |
| Tiempo disponible   | <15 min/semana para análisis.                     | 15-30 min/semana.                                         | 30-60 min/semana.                                  |

| Dimensión                       | Caótica (Ferretería)                  | Emergente (Tecnología)                | Estructurada (Librería)                     |
|---------------------------------|---------------------------------------|---------------------------------------|---------------------------------------------|
| Adopción esperada de plataforma | Necesita guía paso a paso muy simple. | Adopta con ejemplo y práctica guiada. | Adopta rápido; podría ser usuario avanzado. |

## Descripción detallada por perfil

### Perfil A — Madurez Caótica (Ferretería El Clavo Dorado)

Este perfil representa el segmento de mayor prioridad de intervención y, simultáneamente, el de mayor riesgo de abandono si la plataforma es compleja. El dueño o gerente de madurez caótica opera sin ningún sistema de registro estructurado: las decisiones de inventario se toman en base a ofertas de proveedores, intuición acumulada y observación del local. No existe conciencia clara de cuáles productos son más rentables, qué meses son de mayor demanda ni qué combinaciones de productos mueven más volumen.

La plataforma KDD debe abordar este perfil con una Capa 1 ultra-simple: formularios de captura en papel o en Google Forms, con instrucciones visuales y un tiempo de adopción inferior a 30 minutos. El valor percibido debe ser inmediato: si en la primera semana de uso la plataforma le dice 'vendes más cemento en abril que en enero', el dueño adopta el sistema. Si la primera interacción requiere configuración técnica, abandona.

### Perfil B — Madurez Emergente (TechZone Satélite)

Este perfil representa el segmento de mayor masa crítica potencial: la mayoría de las tiendas de tecnología medianas en México operan en este nivel. El dueño tiene alguna forma de registro (ticket del sistema POS, hoja de cálculo básica), reconoce que comete errores de inventario y puede articular qué información le habría ayudado a evitarlos. Sin embargo, no tiene métodos para extraer conocimiento de sus propios datos.

La plataforma KDD puede abordar este perfil con la Capa 2: un dashboard de EDA que conecte directamente con el sistema POS existente y muestre tres indicadores clave (ticket promedio, rotación por categoría, segmentos de mayor valor) en una sola pantalla. El tiempo

de adopción objetivo es menor a 60 minutos. El caso RetailMax del Módulo 1 fue diseñado precisamente para modelar este perfil.

### Perfil C — Madurez Estructurada (Librería Letra Viva)

Este perfil representa el segmento de menor urgencia de intervención básica pero de mayor potencial de impacto avanzado. El dueño ya tiene una comprensión intuitiva de conceptos analíticos (segmentación, incrementalidad, perfil de cliente) y practica análisis informales de manera manual. La plataforma KDD debe ofrecerle la Capa 3: un motor de recomendaciones y análisis de asociaciones entre géneros literarios y perfiles de autor que automatice lo que el dueño ya hace manualmente con 5 o 6 clientes, pero escalado a 300.

Este perfil es también el candidato ideal para la fase de validación del prototipo (Fase 4 del proyecto integrador), ya que su mayor sofisticación le permite dar retroalimentación técnica más detallada y evaluar la plataforma con criterios más exigentes.

### Decisiones Críticas Recurrentes por Segmento

A partir del análisis de los registros de entrevista, el equipo identificó las decisiones que cada tipo de minorista debe tomar con mayor frecuencia y con mayor impacto en la supervivencia del negocio. Estas decisiones se convierten en los casos de uso prioritarios que la plataforma KDD debe resolver en su primera versión.

### Tienda de Tecnología (Perfil Emergente)

| # | Decisión crítica                              | Frecuencia | Necesidad KDD                                                               |
|---|-----------------------------------------------|------------|-----------------------------------------------------------------------------|
| 1 | ¿Cuánto stock pedir de cada categoría?        | Mensual    | Análisis de rotación por SKU y categoría con historial de 3 meses           |
| 2 | ¿Qué productos combinar para aumentar ticket? | Semanal    | Reglas de asociación: qué productos se compran juntos (análisis de canasta) |
| 3 | ¿Qué segmento de cliente atrae más margen?    | Mensual    | Segmentación por ticket promedio: Individual vs. PyME vs. Empresa           |

| # | Decisión crítica                                  | Frecuencia | Necesidad KDD                                                       |
|---|---------------------------------------------------|------------|---------------------------------------------------------------------|
| 4 | ¿Vale la pena el descuento del 15% en accesorios? | Bimestral  | Análisis de elasticidad: variación de volumen vs. pérdida de margen |
| 5 | ¿En qué meses reforzar inventario?                | Trimestral | Detección de estacionalidad y picos de demanda por categoría        |

### Ferretería Especializada (Perfil Caótico)

| # | Decisión crítica                                     | Frecuencia | Necesidad KDD                                                                            |
|---|------------------------------------------------------|------------|------------------------------------------------------------------------------------------|
| 1 | ¿Cuándo y cuánto comprar al proveedor con descuento? | Mensual    | Análisis de demanda estacional local por categoría (no datos nacionales del proveedor)   |
| 2 | ¿Qué productos colocar juntos en el piso de ventas?  | Semestral  | Análisis de asociación: pares de productos frecuentemente comprados juntos               |
| 3 | ¿Cuáles productos tienen exceso de inventario?       | Quincenal  | Clasificación ABC por rotación: A=alta, B=media, C=baja/obsoleta                         |
| 4 | ¿A quiénes dar crédito sin riesgo de morosidad?      | Mensual    | Historial de pago y frecuencia de compra por cliente                                     |
| 5 | ¿Qué promoción funciona para mover inventario lento? | Bimestral  | Clasificación de productos por elasticidad vs. categorías que no se mueven con descuento |



## Librería Independiente (Perfil Estructurado)

| # | Decisión crítica                                                   | Frecuencia      | Necesidad KDD                                                                       |
|---|--------------------------------------------------------------------|-----------------|-------------------------------------------------------------------------------------|
| 1 | ¿A quién notificar cuando llega una novedad de cierto autor?       | Semanal         | Perfil de cliente por autor/género frecuente; sistema de alerta personalizada       |
| 2 | ¿Cuántos ejemplares pedir de un título nuevo?                      | Por lanzamiento | Predicción de demanda basada en historial de autor y género similar                 |
| 3 | ¿La promoción atrae clientes nuevos o solo descuenta a habituales? | Bimestral       | Análisis de incrementalidad: comparar comportamiento de compradores con y sin cupón |
| 4 | ¿Qué géneros se compran juntos en la misma visita?                 | Mensual         | Análisis de canasta literaria: asociaciones entre géneros en una misma transacción  |
| 5 | ¿Qué clientes están en riesgo de no volver?                        | Trimestral      | Análisis de recencia: identificar clientes con compra más de 90 días atrás          |

## Especificación de Necesidades KDD por Impacto

La siguiente tabla consolida las necesidades de KDD identificadas para los tres perfiles, priorizadas por su impacto en la supervivencia del negocio (criterio de máxima prioridad según el instructivo), su viabilidad de implementación con tecnologías gratuitas o de bajo costo, y su relevancia transversal (si aplica a los tres tipos de minorista o solo a uno).

| # | Necesidad KDD                                       | Impacto | Viabilidad | Perfiles               | Módulo KDD                     |
|---|-----------------------------------------------------|---------|------------|------------------------|--------------------------------|
| 1 | Análisis de rotación y estacionalidad por categoría | Crítico | Alta       | Todos                  | Fase 3: EDA + Dashboard        |
| 2 | Segmentación de clientes por ticket y frecuencia    | Crítico | Alta       | Tecnología, Librería   | Fase 3: Motor de reglas        |
| 3 | Reglas de asociación entre productos (canasta)      | Alto    | Alta       | Todos                  | Módulo 3: Apriori/FP-Growth    |
| 4 | Clasificación ABC de inventario por rotación        | Alto    | Alta       | Ferretería, Tecnología | Fase 3: Motor de reglas        |
| 5 | Perfil de cliente por autor/categoría               | Medio   | Media      | Librería               | Módulo 3: Clustering           |
| 6 | Análisis de elasticidad precio-volumen              | Medio   | Media      | Tecnología, Librería   | Módulo 3: Regresión            |
| 7 | Análisis de incrementalidad de promociones          | Medio   | Baja       | Librería               | Módulo 4: A/B testing simulado |
| 8 | Predicción de demanda por lanzamiento               | Bajo    | Baja       | Librería               | Módulo 4: Series de tiempo     |
| 9 | Análisis de recencia (clientes en riesgo)           | Medio   | Alta       | Todos                  | Fase 3: Motor de reglas        |

| #  | Necesidad KDD                  | Impacto | Viabilidad | Perfiles   | Módulo KDD             |
|----|--------------------------------|---------|------------|------------|------------------------|
| 10 | Historial de pago para crédito | Bajo    | Media      | Ferretería | Fuera del alcance v1.0 |

#### Leyenda de prioridad:

Crítico: sin esta capacidad, el negocio toma decisiones que amenazan directamente su rentabilidad. Alto: capacidad que genera diferenciación competitiva clara. Medio: mejora el desempeño pero no es urgente. Bajo: beneficio marginal o de largo plazo.

## Fase 2: Diseño de la Arquitectura

### Introducción

La fase de diseño de la arquitectura tiene como objetivo traducir las necesidades de negocio identificadas en la Fase 1 en una solución técnica viable, accesible y escalable para PYMES minoristas.

A diferencia de entornos corporativos, donde existen infraestructuras robustas y herramientas especializadas, las PYMES operan bajo restricciones severas de:

- Presupuesto limitado
- Baja madurez analítica
- Tiempo reducido para análisis
- Infraestructura tecnológica básica

Por ello, la arquitectura propuesta no busca replicar soluciones empresariales complejas, sino diseñar una **Plataforma KDD simplificada**, basada en herramientas gratuitas o de bajo costo, que permita a los dueños transformar datos en decisiones accionables.

## Enfoque de Arquitectura en Tres Capas

La arquitectura se estructura en **tres capas progresivas**, alineadas con los niveles de madurez analítica identificados:

| Capa   | Objetivo                           | Perfil objetivo |
|--------|------------------------------------|-----------------|
| Capa 1 | Comprensión y preparación de datos | Caótico         |
| Capa 2 | Análisis exploratorio (EDA)        | Emergente       |
| Capa 3 | Recomendaciones accionables        | Estructurado    |

### Capa 1: Comprensión y Preparación (Base del KDD)

#### Objetivo

Guiar al usuario en las primeras fases del proceso KDD:

- Comprensión del negocio
- Comprensión de los datos
- Preparación de los datos (ETL básico)

#### Herramientas propuestas

- Google Sheets
- Google Forms

#### Funcionalidades

##### 1. Captura de datos simplificada

- Registro de ventas (fecha, producto, precio, cantidad)
- Registro de clientes (opcional)
- Registro de inventario

## **2. Plantillas preconfiguradas**

- Control de ventas diario
- Inventario básico
- Registro de promociones

## **3. Pipeline ETL básico**

- Eliminación de registros incompletos
- Normalización de categorías
- Cálculo automático de:
  - Total de ticket
  - Frecuencia de compra
  - Clasificación de productos

## **4. Validación de datos**

- Detección de valores nulos
- Identificación de inconsistencias

### **Valor para el negocio**

- Permite pasar de decisiones intuitivas a decisiones basadas en datos
- Introduce al usuario al pensamiento analítico sin complejidad técnica

## **Capa 2: Análisis Exploratorio (EDA)**

### **Objetivo**

Visualizar patrones clave del negocio para apoyar la toma de decisiones.

### **Herramienta principal**

Google Data Studio (Looker Studio)

### **Dashboard propuesto**

El dashboard incluirá las siguientes visualizaciones:

#### **1. Distribución de tickets**

- Ticket promedio
- Tickets altos vs bajos
- Histograma de ventas

## **2. Estacionalidad**

- Ventas por mes
- Identificación de meses pico
- Tendencias de demanda

## **3. Segmentación de clientes**

- Ticket promedio por segmento
- Frecuencia de compra
- Clientes de alto valor

## **4. Rotación de productos**

- Productos más vendidos
- Productos de baja rotación
- Clasificación ABC

## **5. Canales de venta**

- Tienda vs Web vs Teléfono
- Comparación de rendimiento

## **Valor para el negocio**

- Permite responder preguntas clave:
  - ¿Qué productos se venden más?
  - ¿Cuándo vender más?
  - ¿Quiénes son mis mejores clientes?

## **Capa 3: Sistema de Recomendaciones Accionables**

### **Objetivo**

Transformar los hallazgos del análisis en decisiones concretas.

### **Tipo de sistema**

Motor de reglas basado en lógica simple (no requiere IA compleja).

### **Ejemplos de reglas**

#### **1. Ventas cruzadas**

- "Clientes que compran laptops tienen alta probabilidad de comprar audífonos"

#### **2. Inventario**

- "Producto con baja rotación → reducir compra próxima"

#### **3. Segmentación**

- "Clientes frecuentes → enviar promociones personalizadas"

#### **4. Estacionalidad**

- "Mes con alta demanda → aumentar inventario"

#### **5. Promociones**

- "Producto con baja rotación + alta elasticidad → aplicar descuento"

### **Implementación**

- Reglas configuradas en Google Sheets
- Uso de fórmulas y lógica condicional
- Salida en forma de recomendaciones automáticas

### **Valor para el negocio**

- Convierte datos en acciones inmediatas
- Reduce la incertidumbre en decisiones

## Diagrama de Flujo del Proceso KDD Adaptado a PYMES



## Ontología de Métricas por Industria

### Tecnología

- Ticket promedio
- Ventas cruzadas
- Margen por producto

### Ferretería

- Rotación de inventario
- Clasificación ABC
- Estacionalidad por producto

### Librería

- Frecuencia de compra



- Afinidad por género/autor
- Retención de clientes

## **Conclusión de la Fase**

La arquitectura propuesta permite implementar el proceso KDD completo en un entorno accesible para PYMES, respetando sus limitaciones tecnológicas y operativas.

El enfoque en tres capas garantiza una adopción progresiva:

- Primero: entender y organizar datos
- Después: visualizar información
- Finalmente: tomar decisiones inteligentes

Esta arquitectura no solo es técnicamente viable, sino también culturalmente adecuada, ya que respeta la forma en que los dueños toman decisiones, mientras introduce gradualmente el uso de datos como herramienta estratégica.

## **FASE 3: IMPLEMENTACIÓN DEL PROTOTIPO FUNCIONAL**

### **Introduccion**

La fase de implementación del prototipo funcional tiene como propósito materializar, en una versión inicial pero operativa, los componentes esenciales de la Plataforma KDD para PYMES Minoristas. A diferencia de la fase de diseño arquitectónico, en esta etapa se construyen artefactos concretos que permiten validar la utilidad del enfoque propuesto en un entorno realista, aunque controlado.

El desarrollo se plantea bajo un esquema incremental y centrado en valor inmediato, priorizando primero los elementos que aportan mayor utilidad para el usuario final: la definición clara del problema, la preparación automatizada de datos, la visualización exploratoria básica y la generación de recomendaciones accionables. Esta estrategia permite entregar un prototipo funcional con tecnologías accesibles, bajo costo y fácil adopción por parte de pequeñas y medianas empresas.

## **Objetivo de la fase**

Implementar un prototipo funcional de la Plataforma KDD que integre captura de necesidades del negocio, proceso ETL, análisis exploratorio de datos y generación de recomendaciones, utilizando herramientas accesibles como Google Workspace, Python y datasets sintéticos, con el fin de demostrar la viabilidad técnica y operativa del sistema en un contexto PYME.

## **1. Asistente de Comprensión del Negocio**

### **Descripción**

El primer componente del prototipo consiste en un asistente interactivo orientado a guiar al dueño o gerente de la PYME a través de un proceso breve de reflexión analítica. Su finalidad es traducir una necesidad general de negocio en un objetivo analítico claro, medible y útil para la toma de decisiones.

### **Función dentro del prototipo**

Este asistente actúa como punto de entrada de la plataforma, ya que permite estructurar el problema antes de trabajar con datos. Su diseño responde a una necesidad recurrente en PYMES: muchas decisiones se toman de forma intuitiva, sin una formulación formal del problema.

### **Estructura propuesta**

El formulario incluye cinco preguntas clave:

1. ¿Qué problema de negocio desea resolver?
2. ¿Qué información tiene disponible actualmente?
3. ¿Qué decisión concreta quiere mejorar?
4. ¿Qué resultado espera obtener?
5. ¿Cómo sabrá que la solución fue útil?

### **Salida esperada**

A partir de las respuestas, el sistema genera un resumen del objetivo analítico, por ejemplo:

“Identificar productos que se compran juntos para aumentar el ticket promedio mediante promociones cruzadas.”

### **Valor aportado**

Este componente reduce la ambigüedad inicial y ayuda a que el usuario piense en términos de negocio, no solo de datos. En el contexto del KDD, esto fortalece la fase de comprensión del negocio y prepara el camino para el análisis posterior.

## **2. Pipeline ETL**

### **Descripción**

El segundo componente es un script en Python encargado de automatizar la extracción, transformación y carga de datos provenientes de archivos CSV exportados desde sistemas existentes como ERP, CRM o registros de ventas.

### **Función dentro del prototipo**

Este pipeline constituye el núcleo técnico de la preparación de datos. Su objetivo es convertir datos crudos en una estructura analítica confiable, consistente y lista para consulta.

### **Procesos principales**

El pipeline realiza las siguientes operaciones:

- Lectura de archivos CSV.
- Validación de estructura y tipos de datos.
- Tratamiento de valores nulos.
- Estandarización de categorías textuales.
- Detección de registros inconsistentes.
- Generación de variables derivadas.
- Construcción de un esquema estrella.

### **Transformaciones aplicadas**

Entre las transformaciones más relevantes se incluyen:

- Cálculo de total\_ticket.
- Normalización de campos como segmento, producto y canal.

- Creación de variables temporales como mes, trimestre y día de la semana.
- Clasificación de tickets altos y bajos.
- Marcado de posibles outliers.

### **Esquema estrella**

El pipeline genera una estructura dimensional compuesta por:

- **Tabla de hechos:** ventas.
- **Dimensión tiempo:** fecha, mes, trimestre, día.
- **Dimensión producto:** categoría, nombre, subcategoría.
- **Dimensión cliente:** segmento, tipo, frecuencia.
- **Dimensión canal:** tienda, web, teléfono.
- **Dimensión ubicación o tienda:** sucursal, región, zona.

### **Valor aportado**

Este componente garantiza que el análisis posterior se realice sobre datos limpios, organizados y consistentes. Además, hace posible reutilizar la información en futuras fases del proyecto, como el EDA y el modelado.

## **3. Dashboard de EDA**

### **Descripción**

El tercer componente del prototipo es un dashboard exploratorio que permite visualizar rápidamente el comportamiento del negocio a través de indicadores clave. Su objetivo es resumir patrones importantes sin requerir conocimientos técnicos avanzados.

### **Función dentro del prototipo**

Este dashboard traduce los datos procesados en visualizaciones comprensibles para el usuario final, facilitando la detección de tendencias, anomalías y oportunidades comerciales.

### **Visualizaciones incluidas**

#### **a) Distribución de tickets**

Esta sección muestra cómo se distribuyen los montos de compra. Permite identificar:

- tickets bajos,
- tickets promedio,
- tickets altos,
- posibles valores atípicos.

#### **b) Tendencia mensual**

Presenta la evolución de las ventas por mes e incorpora líneas de referencia para reconocer aumentos o caídas significativas. Esto ayuda a detectar:

- estacionalidad,
- meses pico,
- meses de bajo desempeño.

#### **c) Segmentos de alto valor**

Muestra comparaciones entre segmentos de clientes para identificar cuáles generan mayor valor para el negocio, ya sea por ticket promedio, frecuencia de compra o contribución total.

#### **Valor aportado**

El dashboard convierte el análisis exploratorio en una herramienta de consulta rápida, visual y práctica. Para una PYME, esto es especialmente importante porque permite interpretar datos sin depender de reportes extensos o conocimiento estadístico profundo.

### **4. Generador de Recomendaciones**

#### **Descripción**

El último componente del prototipo es un motor de reglas que analiza los resultados del EDA y produce sugerencias concretas de acción. No se trata todavía de un modelo predictivo complejo, sino de una capa de interpretación orientada al negocio.

#### **Función dentro del prototipo**

Su finalidad es cerrar el ciclo KDD llevando los hallazgos analíticos a decisiones operativas comprensibles y justificadas.

#### **Lógica de funcionamiento**

El sistema evalúa patrones detectados en el análisis y activa reglas del tipo:

- Si un producto tiene alta coocurrencia con otro, sugerir venta cruzada.
- Si un segmento presenta ticket alto, priorizar promociones personalizadas.
- Si un producto tiene baja rotación, sugerir ajuste de inventario.
- Si un mes presenta alta demanda, recomendar refuerzo de stock.

### **Ejemplo de salida**

“Promociona el combo laptop + auriculares porque el 42% de las PYMEs que compran laptop también adquieren auriculares.”

### **Valor aportado**

Este componente traduce resultados estadísticos en decisiones accionables. Para el usuario final, esto representa el verdadero valor del sistema: no solo ver datos, sino saber qué hacer con ellos.

### **Tecnologías utilizadas**

El prototipo se implementa con tecnologías accesibles y de bajo costo:

- **Google Forms** para captura de necesidades del negocio.
- **Google Sheets** para almacenamiento y validación básica.
- **Python** para el desarrollo del pipeline ETL y del motor de reglas.
- **Google Looker Studio** para el dashboard de EDA.
- **Servidor económico o entorno ligero** para ejecución de scripts, con costo aproximado de **\$5 USD/mes** o menos.

Esta selección tecnológica responde a la necesidad de mantener una solución económica, replicable y adecuada para PYMES con recursos limitados.

### **Flujo funcional del prototipo**

El prototipo opera mediante el siguiente flujo:

1. El usuario responde el asistente de negocio.
2. Los datos se cargan desde archivos CSV o formularios.

3. El pipeline ETL limpia, transforma y estructura la información.
4. El dashboard muestra patrones relevantes del negocio.
5. El motor de reglas interpreta los hallazgos.
6. El sistema entrega recomendaciones accionables.
7. El usuario toma decisiones informadas.

## **Validación del prototipo**

La validación inicial del prototipo se enfoca en comprobar que cada componente cumpla su función prevista:

- que el asistente ayude a formular un objetivo analítico claro;
- que el ETL procese correctamente los datos sintéticos;
- que el dashboard muestre patrones útiles;
- que las recomendaciones sean comprensibles y coherentes con los hallazgos del análisis.

La validación no busca aún optimizar modelos predictivos complejos, sino demostrar la viabilidad funcional del sistema dentro del contexto del proyecto.

## **Conclusión de la fase**

La implementación del prototipo funcional permite consolidar la propuesta de la Plataforma KDD para PYMES Minoristas en una versión inicial operativa, útil y coherente con las limitaciones reales del entorno PYME. A través de la integración de un asistente de negocio, un pipeline ETL, un dashboard exploratorio y un motor de recomendaciones, se establece una base técnica sólida para la continuación del proyecto.

Esta fase demuestra que es posible aplicar minería de datos de forma gradual, económica y orientada a valor, transformando datos crudos en información comprensible y, posteriormente, en decisiones accionables para el negocio.

## Fase 5: Estrategia de Adopción y Sostenibilidad

### 1. Guía de implementación

Tiempo estimado: 45–60 minutos

#### Paso 1: Preparar archivos

- Descargar la carpeta del proyecto
- Verificar que contiene CSV, script Python y configuración

#### Paso 2:

- Ejecutar el sistema
- Abrir `pipeline_kdd_2026.py`
- Ejecutarlo con Python
- Esperar a que finalice

#### Paso 3:

- Generación de resultados
- Dataset limpio
- Esquema estrella
- Archivo JSON con métricas

#### Paso 4:

- Interpretar resultados
- Revisar JSON
- Analizar ticket promedio y ventas cruzadas

#### Paso 5:

- Toma de decisiones



- Mejorar combinaciones de productos
- Aumentar valor por compra
- Reducir ventas de bajo valor

## **2. Kit de comunicación**

- Estamos implementando análisis de datos para tomar decisiones más inteligentes.
- Nos ayudará a entender qué productos se venden juntos.
- No reemplaza experiencia, la complementa.
- El objetivo es vender mejor, no trabajar más.
- Buscamos reducir desperdicio y mejorar ingresos.

## **3. Métricas de éxito**

- Incremento del 12% en ticket promedio
- Reducción del 15% en transacciones de bajo valor
- Incremento del 20% en ventas cruzadas

## **Métricas adicionales**

- Reducción de inventario obsoleto
- Mejora en decisiones comerciales
- 

## **Indicador ROI**

Se evaluará considerando aumento de ingresos, optimización de inventario y eficiencia en decisiones.